

Inferência Bayesiana

Inferência sobre o parâmetro de forma da Gamma

Eduardo E. R. Junior

Conjunto de dados

O conjunto de dados utilizado neste exemplo é apresentado abaixo:

```
[1] 0.8 1.5 2.6 1.5 1.4 2.1 3.9 3.3 3.0 3.9 4.2 4.8 6.9 5.5  
[15] 7.3 6.7 8.2 8.1 10.2 10.7 12.8
```

São 21 observações que provêm de um processo aleatório Gama com parâmetro de locação conhecido ($\alpha = 2$) e estamos interessados na inferência sobre a dispersão do processo, controlada pelo parâmetro θ .

A distribuição Gama

Uma variável aleatória Y segue o modelo Gama, se sua densidade for dada por

$$f_Y(y | \alpha, \theta) = \frac{\theta^{-\alpha}}{\Gamma(\alpha)} y^{\alpha-1} e^{-\theta y} \quad (1)$$

$$f_Y(y | \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y} \quad (2)$$

em que $\alpha > 0$, $\theta > 0$ e $\beta > 0$. Aqui são apresentadas duas diferentes parametrizações da distribuição Gama. A primeira apresentada em (1) possui $E[Y] = \alpha\theta$ e a variância por $\text{Var}[Y] = \alpha\theta^2$. A segunda (2), por sua vez tem as expressões para média e variância dadas por $E[Y] = \alpha/\beta$ e $\text{V}[Y] = \alpha/\beta^2$. As parametrizações adotadas aqui se referem, propositalmente ao parâmetro de escala, sob investigação. Ainda as duas definições se relacionam sob a transformação $\theta = 1/\beta$.¹

Inferência via Verossimilhança

Abaixo são definidas analiticamente as funções de *verossimilhança* $L(\theta; y)$; *log-verossimilhança* $l(\theta; y)$; *escore* $U(\theta)$; *Hessiana* $H(\theta)$; e *Informação esperada de Fisher* $I_E(\theta)$. Com elas temos todos os elementos necessários para inferência estatística baseada em verossimilhança, a partir de uma amostra.

¹Há diversas outras parametrizações que podem ser consideradas para a distribuição Gama. No R, as funções `d`, `p`, `q` e `r` de sufixo `gamma` provêm duas parametrizações aqui consideradas.

$$L(\theta; y) = \prod_{i=1}^n \left(\frac{\theta^{-\alpha}}{\Gamma(\alpha)} y_i^{\alpha-1} e^{\theta^{-1} y_i} \right)$$

$$l(\theta; y) = -n\alpha \log(\theta) - n \log(\Gamma(\alpha)) +$$

$$(\alpha - 1) \sum_{i=1}^n \log(y_i) - \theta^{-1} \sum_{i=1}^n y_i$$

$$U(\theta) = \frac{-n\alpha}{\theta} + \frac{\sum_{i=1}^n y_i}{\theta^2}$$

$$H(\theta) = \frac{n\alpha}{\theta^2} - \frac{2 \sum_{i=1}^n y_i}{\theta^3}$$

$$I_E(\theta) = E[-H(\theta; y)] = \frac{n\alpha}{\theta^2}$$

$$L(\beta; y) = \prod_{i=1}^n \left(\frac{\beta^\alpha}{\Gamma(\alpha)} y_i^{\alpha-1} e^{\beta y_i} \right)$$

$$l(\beta; y) = n\alpha \log(\beta) - n \log(\Gamma(\alpha)) +$$

$$(\alpha - 1) \sum_{i=1}^n \log(y_i) + \beta \sum_{i=1}^n y_i$$

$$U(\beta) = \frac{-n\alpha}{\beta} + \sum_{i=1}^n y_i$$

$$H(\beta) = \frac{-n\alpha}{\beta^2}$$

$$I_E(\beta) = E[-H(\beta; y)] = \frac{n\alpha}{\beta^2}$$

Para encontrar $\hat{\theta}$, uma estimativa do parâmetro θ , resolvemos a equação $U(\theta) = 0$, ainda uma medida de incerteza sobre esta estimativa pode ser obtida pelo inverso da informação de Fisher, $\text{Var}[\hat{\theta}] = I_E^{-1}(\theta)$

Analiticamente temos:

$$U(\theta; y) = 0 \Rightarrow \hat{\theta} = (n - \alpha)^{-1} \sum_{i=1}^n y_i$$

Obtendo a estimativa de θ via expressão analítica temos:

```
##-----
## Obtendo as estimativas analiticamente
alpha.f <- 2
MLEana <- sum(y) / (length(y)*alpha.f); MLEana
```

```
[1] 2.604762
```

```
sum(y) / (length(y)*alpha.f)
```

```
[1] 2.604762
```

```
(length(y)*alpha.f) / sum(y)
```

```
[1] 0.3839122
```

E para as demais medidas de incerteza sobre o ajuste definimos as seguintes funções no R

```

## Escore
Ufun <- function(par, alpha = alpha.f, y,
                 parametrization = c("theta", "alpha")) {
  n <- length(y); soma <- sum(y)
  out <- -n * alpha * par^(-1)
  if (parametrization[1] == "beta") {
    out <- out + soma
  } else {
    out <- out + soma * par^(-2)
  }
  return(out)
}

## Hessiana
Hfun <- function(theta, alpha = alpha.f, y,
                 parametrization = c("theta", "alpha")) {
  n <- length(y)
  out <- -n * alpha * theta^(-2)
  if (parametrization[1] == "theta") {
    out <- -out - 2 * sum(y) * theta^(-3)
  }
  return(out)
}

## Informação esperada
Iefun <- function(theta, alpha = alpha.f, y) {
  ## Invariante a parametrização
  n <- length(y)
  out <- n * alpha * theta^(-2)
  return(out)
}

```

Adicionalmente definimos a função de log-verossimilhança para verificar se as expressões calculadas conferem seu máximo quando aplicadas no exemplo

```

## log-verossimilhança
lfun <- function(par, alpha = alpha.f, y, log = TRUE,
                 parametrization = c("theta", "beta")) {
  if (parametrization[1] == "beta") {
    theta <- 1/par
  } else {
    theta <- par
  }
  n <- length(y)
  ## res <- sum(dgamma(x = y, shape = alpha, scale = theta, log = TRUE))
  out <- -n * alpha * log(theta) - n * lgamma(alpha) +
    (alpha - 1) * sum(log(y)) - theta^(-1) * sum(y)

```

```

if(!log) out <- exp(out)
attr(out, "parametrization") <- parametrization
attr(out, "alpha") <- alpha.f
return(out)
}

```

Observando o ajuste

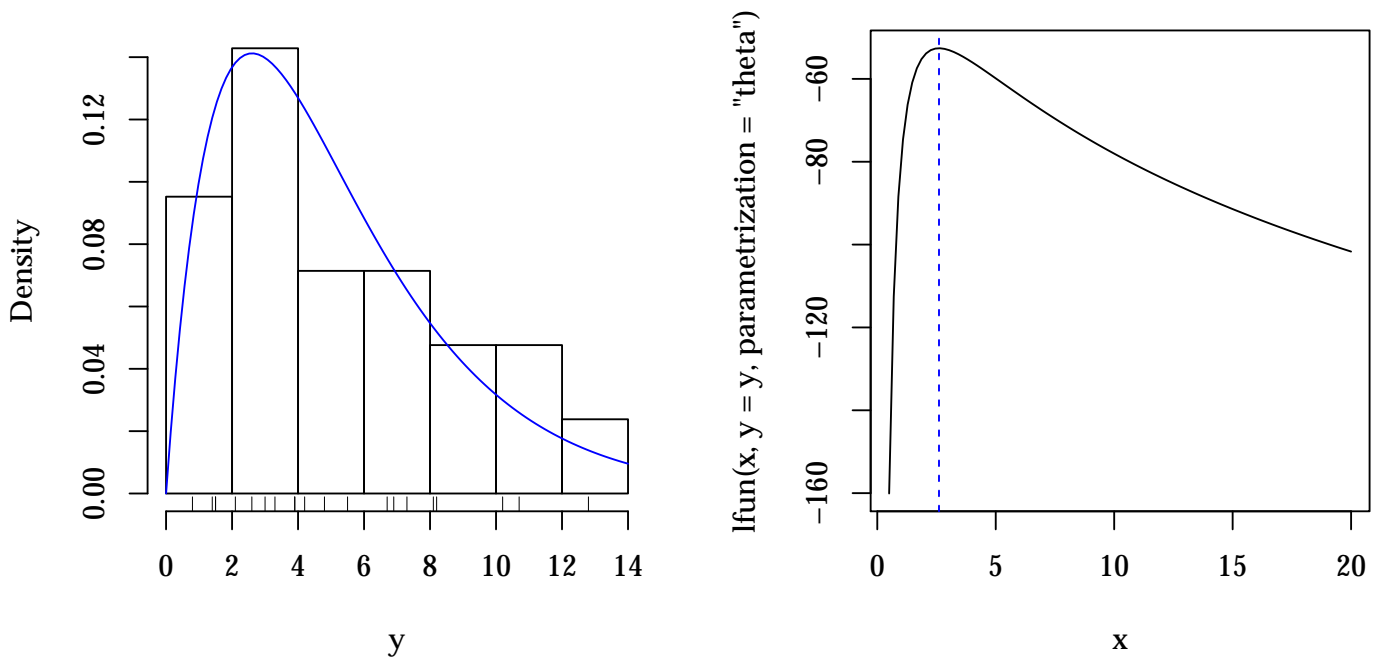
```

## Calculando conforme expressão analitica
alpha.f <- 2
MLEana <- sum(y) / (length(y)*alpha.f)

## Visualizando o ajuste
par(mfrow = c(1, 2))
hist(y, prob = TRUE); rug(y)
curve(dgamma(x, shape = alpha.f, scale = MLEana), col = 4, add = TRUE)
##
curve(lfun(x, y = y, parametrization = "theta"), from = 0.5, to = 20)
abline(v = MLEana, lty = 2, col = 4)

```

Histogram of y




Estudando de diferentes parametrizações

```

par(mfrow = c(1, 2))
curve(lfun(x, y = y, parametrization = "theta"), from = 0.5, to = 20)
curve(lfun(x, y = y, parametrization = "beta"), from = 1e-2, to = 1.3)

```



Inferência Bayesiana

Em inferência Bayesiana tratamos o parâmetro de interesse como variável aleatória e, através do teorema de Bayes, definimos sua função de densidade de probabilidade e assim todas as inferências são derivadas dela.

$$f(\theta; y) = f(\theta)L(\theta; y) \quad (3)$$

Priori de Jeffreys

Uma das características da inferência Bayesiana é que podemos (devemos) incluir uma informação a priori a respeito do parâmetro de interesse, ou seja, àquela cujo temos antes de se realizar o experimento e se coletar os dados. Em muitas situações não temos o que acrescentar sobre o parâmetro e desejamos representar nossa ignorância com funções a priori vagas, porém definir funções a priori que sejam vagas não é uma tarefa fácil. Um dos principais defeitos de prioris vagas é que elas são vagas somente em certa escala do parâmetro, ou seja, é como se seu conhecimento sobre o parâmetro variasse conforme a parametrização utilizada.

Uma das saídas para esta situação é adotar a priori de Jeffreys que contém a mesma informação, invariavelmente à transformação do parâmetro. A priori de Jeffreys é definida como $f(\theta) = |I_E(\theta)|^{1/2}$. No exemplo Gama a priori de Jeffreys, tomando a expressão da Informação de Fisher em (6) é

$$f(\theta) = \left| \frac{n\alpha}{\theta^2} \right|^{1/2} \propto \theta^{-1} \quad (4)$$

Posteriori

Substituindo as expressões (8) e (2), sem as constantes de proporcionalidades, na expressão (7) temos a função a posteriori da seguinte forma:

$$\begin{aligned} f(\theta; y) &\propto \theta^{-1} \theta^{-n\alpha} \exp \left\{ -\theta^{-1} \sum_{i=1}^n y_i \right\} \\ &\propto \theta^{-n\alpha-1} \exp \left\{ -\sum_{i=1}^n y_i (\theta^{-1}) \right\} \end{aligned} \quad (5)$$

E neste exemplo conseguimos reconhecer o núcleo da distribuição, pois a distribuição Gama Inversa possui densidade de probabilidade na forma:

$$\begin{aligned} Y &\sim \text{InvGama}(a, b) \\ f_Y(y, a, b) &= \frac{b^{-a}}{\Gamma(a)} y^{-a-1} \exp \{ -b^{-1} y^{-1} \} \end{aligned}$$

E notamos que a posteriori segue este modelo *InverseGama* de parâmetros $a = n\alpha$ e $b = 1 / \sum_{i=1}^n y_i$. Neste exemplo também pôde-se obter as expressões analíticas para as verossimilhanças, encaixando-as em modelos de probabilidade já conhecidos. Abaixo apresentamos os gráficos da posteriori e verossimilhança para as duas parametrizações

```
## Define a função da densidade da InverseGama
dinvgamma <- function(x, a, b, log = FALSE) {
  res <- ifelse(
    x > 0,
    -a * log(b) - log(gamma(a)) - (a + 1)*log(x) - 1/(b*x),
    -Inf)
  if(!log) res <- exp(res)
  return(res)
}

##-----

## Informações do problema
n <- length(y)
soma <- sum(y)
alpha.f <- 2

par(mfrow = c(1, 2))
## Considerando a parametrização com theta
curve(dinvgamma(x, a = n*alpha.f, b = 1/soma),
      from = 1e-5, to = 5)
curve(dinvgamma(x, a = n*alpha.f + 1, b = 1/soma), add = TRUE,
```

```

lty = 2, col = 4)
legend("topleft", c("Verossimilhança", "Posteriori"),
      lty = c(2, 1), col = c(1, 4), bty = "n")
## Considerando a parametrização com beta
curve(dgamma(x, shape = n*alpha.f, rate = soma),
      from = 1e-2, to = 1.3)
curve(dgamma(x, shape = n*alpha.f + 1, rate = soma), add = TRUE,
      lty = 2, col = 4)
legend("topright", c("Verossimilhança", "Posteriori"),
      lty = c(2, 1), col = c(1, 4), bty = "n")

```

